Horario Inteligente: predecir cuándo se ofrecerá cada materia para pre-reservar el horario del siguiente semestre

Proyecto Final Integrador · Machine Learning I (IMPN0004) · Universidad EAN · Equipo Semestria

Integrantes: Bresleny Yanira Benavides Cabiche (líder, Maestría en Ciencia de Datos) · Paula Andrea Bustos (crack, Especialización en Machine Learning). **Entrega:** 22 de octubre de 2026. **Repositorio:** [enlace en el comentario de la entrega]. **Cuaderno:** `cuaderno_PFI.ipynb` (semilla 2026, rutas relativas).

1. Problema y decisión

Contexto. Cada semestre, el estudiante de pregrado presencial de la EAN espera a que se publique la programación académica para armar su horario y compite por cupos en los primeros días de matrícula. Quien trabaja suele tener un patrón estable (por ejemplo, martes y jueves en la noche o sábado en la mañana) y necesita saber pronto si sus materias pendientes caerán en esas franjas.

Idea de producto. Una herramienta que, a partir del horario actual del estudiante, aprende su **perfil de franjas** y le **pre-reserva** las materias pendientes que con alta probabilidad se dictarán en esas franjas el semestre siguiente, antes de que se publique la programación.

Decisión que se apoya. Para cada materia pendiente y cada franja preferida: *¿pre-reservar o no?* La toma el estudiante, con el visto bueno de la Dirección de Registro y Programación Académica, que también puede usar las predicciones para planear la oferta.

A quién afecta. A los estudiantes (sobre todo a quienes trabajan y estudian de noche o el sábado), a Registro, que procesa las reservas, y a las facultades, cuya oferta queda condicionada por las reservas anticipadas.

Formulación de ML. Es aprendizaje **supervisado de clasificación binaria**. La unidad es el par *(materia, franja, periodo t)*. Una franja combina día (lunes a sábado) y jornada (mañana antes de 12:00, tarde de 12:00 a 17:59, noche desde 18:00), lo que da 18 franjas. La etiqueta vale 1 si la materia tiene al menos un grupo en esa franja en *t*. Se eligió el paradigma supervisado porque la historia de programaciones trae la respuesta observada de cada periodo. El problema de reservar varias materias sin choques se resuelve después con una regla sobre las probabilidades (sección 6).

Pérdida técnica frente a métrica de negocio. Los modelos se ajustan con pérdida de entropía cruzada (*cross-entropy loss*) y se comparan por **precisión promedio** (*average precision*, PR-AUC), sensible a la clase minoritaria. El éxito para el negocio se mide con dos cifras. La primera es la **precisión de las reservas**: qué parte de lo reservado sí se abrió. La segunda es el **costo esperado por cada 100 decisiones**, con costo FP:FN = 2:1:

- Un **falso positivo** reserva una franja que no se abre. El estudiante rehace su horario y su plan laboral, pero lo descubre al publicarse la programación, antes de matricular.

- Un **falso negativo** no reserva una franja que sí se abrió. El estudiante queda como hoy, y en franjas apetecidas puede quedarse sin cupo.

Como esta razón es un supuesto, se muestra la sensibilidad a 1:1, 3:1 y 5:1. El modelo se compara con dos reglas: no reservar nada (el statu quo) y repetir la franja del semestre pasado (persistencia).

Riesgos éticos iniciales.

- **Inequidad por jornada:** si el modelo falla más en la noche y el sábado, perjudica a los estudiantes que trabajan.
- **Profecía autocumplida:** si las reservas influyen en la programación, la oferta se congela en el pasado.
- **Datos personales:** la programación trae nombres de docentes; no se usan.
- **Automatización excesiva:** una reserva automática errónea traslada el costo al estudiante.

2. Datos

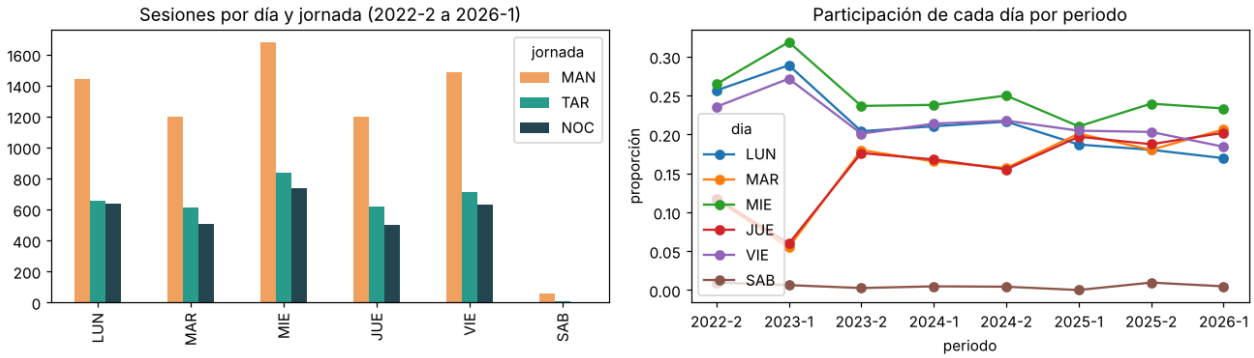
Fuente. Son las programaciones académicas de pregrado presencial que publica la Universidad EAN en su portal de estudiantes (página «Gestión de enlace académico-administrativo», sección «PROGRAMACIÓN ACADÉMICA»): 8 archivos Excel, de 2022-2 a 2026-1, cada uno con hojas por facultad (FIN, FAFCE y FHCS). Son **datos reales observados**, no simulados. La ficha completa está en `ficha_datos.md` y la procedencia en el anexo B.

Tamaño y estructura. Hay 7 155 filas de grupo-horario y 763 códigos de materia. Cada fila trae la materia, el grupo, los créditos, la tipología, el ciclo (C1–C4 de 8 semanas o S1–S2 semestral), las fechas, la hora de inicio y fin, los días marcados con «X», el aula, la sede y el docente.

Unificación. Los archivos no comparten formato. El encabezado está en la fila 6, 12 o 13; los días se llaman `Lunes`, `LUNES`, `Lun` o `L`; las horas vienen como texto, como hora o como fracción de día; y en 2025-2 cambian los nombres de columna. Se escribió una función que detecta el encabezado y homologa columnas por significado. La llave de materia son los primeros 8 caracteres del código, porque los nombres vienen truncados en algunos periodos.

Diagnóstico de calidad (priorizado).

#	Hallazgo	Evidencia	Tratamiento
1	Cobertura desigual entre archivos	2022-2 solo trae el ciclo C4 (245 filas) y 2023-1 solo el C2 (243); 2025-1 trae S1 y C1	Solo sirven como historia (rezagos), nunca como periodo objetivo; se agrega la variable `n_periodos_historia`
2	Deriva del catálogo de códigos	Apenas el 20 % de los códigos de 2025-2 existía en 2025-1, por la migración a códigos «…PN…»	Las materias sin historia quedan fuera del alcance (límite declarado)
3	Tipología sin estandarizar	47 variantes; por ejemplo, «TRANSV OBLIGATORIAS» y «TRANS. OBLIGATORIAS»; 18,8 % faltante (todo 2025-2)	No se usa como predictora
4	Docente ausente o no publicado	65 % de faltantes	Se excluye: es dato personal y no existe al decidir
5	Grupos sin días, sin hora o con hora atípica	49 sin días, 36 sin hora y 16 que empiezan antes de las 6:00 o después de las 22:00	Se excluyen del conteo de franjas
6	Filas repetidas	158 combinaciones repetidas, por grupos con varias sesiones	Se agrega a nivel (materia, franja)



Sesiones por día y jornada y participación de cada día por periodo

Representatividad y sesgo. Los datos describen la **oferta programada**, no la demanda, la matrícula ni las cancelaciones posteriores. Representan el pregrado presencial de las tres facultades en Bogotá; no representan virtual ni posgrado. El **sábado casi no tiene oferta presencial**: es cerca del 1 % de los grupos en todos los periodos (10 grupos en 2026-1). El caso que motivó la idea («si siempre estudias los sábados») es, por eso, el más difícil de predecir.

3. Preparación y diseño experimental

Población evaluada. Se evalúan las materias con historia en *t-1* o *t-2* que abren en *t*. El supuesto de decisión es que el estudiante sabe qué materias le faltan y la universidad anuncia

qué materias abrirá; lo incierto es *cuándo*. Este supuesto define qué filas se evalúan, pero no agrega ninguna variable del periodo *t*. Resultan 21 528 pares en 6 periodos objetivo (2023-2 a 2026-1), con 24 % a 27 % de positivos.

Variables, calculadas solo con periodos anteriores a *t*.

- Presencia en la franja en *t-1* y *t-2*.
- Número de grupos en la franja en *t-1*.
- Fracción histórica de periodos en esa franja.
- Presencia en el mismo día con otra jornada, y en la misma jornada con otro día.
- Número de grupos y de franjas en *t-1*.
- Proporción de grupos en ciclos de 8 semanas.
- Peso global de la franja en *t-1*.
- Semestre objetivo (1 o 2), créditos, día, jornada y facultad.

Columnas excluidas por fuga de disponibilidad o por ética. No entran el docente, el aula, las fechas ni el número de grupos del periodo objetivo, porque no existen el día de decidir; tampoco los nombres de personas. Incluso la facultad y los créditos de cada materia se toman del último periodo **anterior** a *t* en que apareció. En una revisión final detectamos que la primera versión los tomaba de todos los periodos, incluida la prueba, y lo corregimos.

Partición temporal. Para el desarrollo se usan los periodos objetivo 2023-2 a 2025-2, con **validación hacia adelante** en 4 pliegues: se entrena con el pasado y se valida en el periodo siguiente (2024-1, 2024-2, 2025-1 y 2025-2). La **prueba es 2026-1** y se consultó **una sola vez**, después de elegir modelo y umbral. Una partición aleatoria habría mezclado el futuro con el pasado. **¿Por qué no una partición por grupos?** En los retos se partía por colegio o municipio porque el modelo debía servir para grupos nuevos. Aquí la herramienta se usa con las mismas materias en un semestre futuro, así que hay que imitar el paso del tiempo. La dependencia entre las 18 franjas de una materia se respeta en la evaluación con un *bootstrap* que remuestrea materias completas.

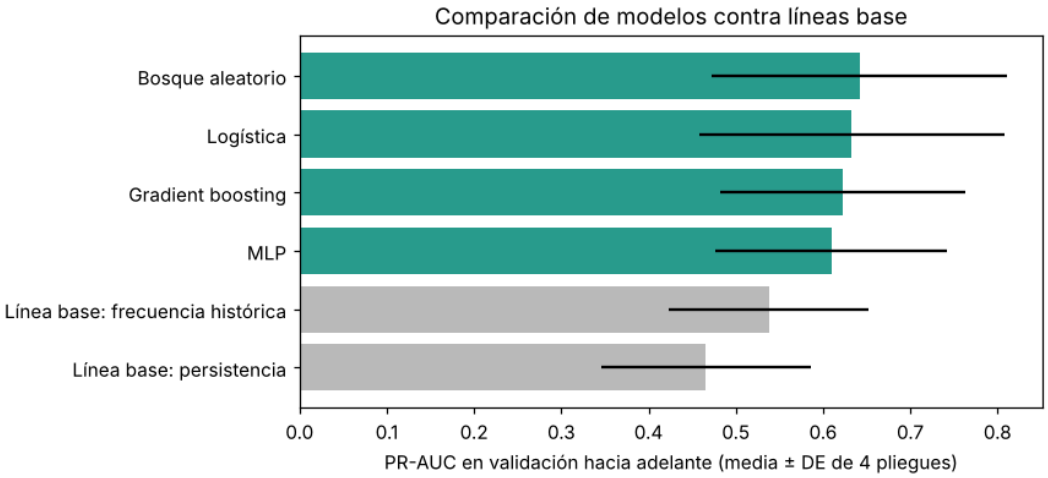
Flujo encapsulado. Cada modelo es un `Pipeline` con `ColumnTransformer`: imputación por mediana, estandarización cuando el modelo la necesita y *one-hot* de las categóricas. El flujo se ajusta dentro de cada pliegue con los datos de entrenamiento.

Desbalance. Cerca de 1 de cada 4 pares es positivo. No se usa ponderación de clases (*class weighting*) ni sobremuestreo sintético (SMOTE), a propósito: la herramienta muestra probabilidades al estudiante y ponderar las clases las infla. Una versión preliminar con `class_weight='balanced'` llevaba el umbral óptimo a 0,95. El desbalance se maneja en la evaluación, con la precisión promedio, y en la decisión, con el umbral de costo.

4. Modelado

Se compararon dos **líneas base** y **cuatro familias** de modelos bajo los mismos pliegues. Los hiperparámetros se eligieron por el PR-AUC medio en validación.

Modelo (mejor hiperparámetro)	PR-AUC validación (media ± DE)	PR-AUC entrenamiento	Brecha	ROC-AUC validación
Base: persistencia (repetir la franja de *t-1*)	0,466 ± 0,121	—	—	0,715
Base: frecuencia histórica	0,538 ± 0,114	—	—	0,768
Regresión logística (C = 0,01)	**0,633 ± 0,175**	0,744	**0,111**	0,819
Bosque aleatorio (hoja mínima = 20)	0,642 ± 0,169	0,817	0,175	0,826
Gradient boosting (tasa de aprendizaje = 0,03)	0,623 ± 0,141	0,857	0,234	0,809
Perceptrón multicapa, capas ocultas 32 y 16, parada temprana (α = 0,1)	0,609 ± 0,133	0,776	0,167	0,791



Comparación de modelos contra líneas base

Criterio de elección, declarado antes de ver la prueba: se elige el mejor PR-AUC medio en validación; si varios quedan a menos de una desviación estándar del mejor, se prefiere el más simple e interpretable. Los cuatro modelos quedaron a menos de una DE del bosque (0,642), así que se eligió la **regresión logística**. Tiene la menor brecha entre entrenamiento y validación, probabilidades interpretables y coeficientes explicables al jurado y a Registro.

Sesgo y varianza. El bosque con hojas pequeñas (0,895 en entrenamiento) y el boosting con tasa de aprendizaje alta (0,915) memorizan: es varianza. Regularizar (hojas de 20 a 50, C pequeño, regularización L2 en el MLP) reduce la brecha entre entrenamiento y validación sin perder validación. El techo cercano a 0,63–0,64 en validación es de **información, no de capacidad**: la programación depende de docentes, aulas y demanda, que no están en los datos.

Qué aprendió. La importancia por permutación, medida en validación 2025-2, muestra que la variable dominante es la **fracción histórica de periodos en esa franja**, seguida del número de grupos y los créditos en *t-1*. Se agregó una **columna de control** de ruido aleatorio: 12 de las 17 variables la superan. La presencia en *t-1* queda por debajo porque su información ya está contenida en la fracción histórica (redundancia). Son **asociaciones**: reflejan inercia administrativa (mismo docente, misma cohorte, misma aula), no una causa.

5. Evaluación

Umbral de decisión por costo, calculado en validación. Con FP:FN = 2:1, el umbral que minimiza el costo con las predicciones fuera de pliegue es **0,71**. Con ese umbral, el modelo reserva el 11 % de los pares.

FP:FN	Umbral	Costo/100 modelo	Costo/100 persistencia	Costo/100 no reservar	% reservado
1:1	0,45	18,4	18,3	24,8	20,0
2:1	**0,71**	**22,7**	26,6	24,8	11,3
3:1	0,96	23,7	34,8	24,8	2,3
5:1	0,96	24,3	51,4	24,8	2,3

Si un falso positivo cuesta 3 veces o más que un falso negativo, el modelo casi no reserva y empata con no hacer nada. En ese escenario la herramienta debe **sugerir, no reservar**.

Estabilidad entre pliegues (2:1). El costo por 100 decisiones fue de 24,96 ± 8,07 para el modelo y de 30,96 ± 14,02 para la persistencia. El modelo fue mejor en 3 de 4 pliegues, y el desempeño cae en 2025-1 y 2025-2, los periodos con más cambios de catálogo.

Prueba 2026-1 (una sola consulta). Los intervalos son *bootstrap* de 500 réplicas que remuestrean materias completas.

Métrica	Modelo (umbral 0,71)	Persistencia	No reservar
Precisión promedio (PR-AUC)	**0,830** [0,789; 0,868]	0,732	—
Precisión de las reservas	**0,904** [0,864; 0,943]	0,827	—
Exhaustividad o *recall* (franjas abiertas que se reservaron)	0,347	**0,832**	0
Costo por 100 decisiones (2:1)	18,8 [17,4; 20,5]	**13,4** [11,0; 15,8]	25,9

Lectura honesta.

1. El modelo **ordena mejor** que la persistencia (PR-AUC 0,83 frente a 0,73) y sus reservas son **más confiables**: 9 de cada 10 se cumplieron.
2. Con el umbral fijado en validación, el modelo **reservó demasiado poco**, y en 2026-1 la regla de persistencia tuvo menor costo total. La diferencia entre persistencia y modelo fue de −7,6 a −3,6 puntos por 100 decisiones con un IC del 95 %, es decir, a favor de la

persistencia. El umbral aprendido en periodos más inestables (2025-1 y 2025-2) no se trasladó a un periodo más estable. **No se re-ajustó el umbral con la prueba.**
3. Ambas reglas superan con holgura al statu quo de no reservar (25,9).

Calibración: por qué reservó tan poco. En prueba, el modelo **subestimó** las probabilidades en el tramo medio y alto. El Brier fue de 0,091.

Probabilidad predicha	Pares	Media predicha	Tasa real
0,1 o menos	1 323	0,05	0,01
0,1 a 0,3	1 950	0,16	0,09
0,3 a 0,5	306	0,42	0,48
0,5 a 0,7	509	0,61	**0,80**
0,7 a 0,9	479	0,77	**0,89**
Más de 0,9	23	0,94	1,00

La programación de 2026-1 fue más estable que la de los periodos de validación, por la deriva de códigos de 2025. Por eso, muchas franjas con probabilidad de 0,5 a 0,7 sí se abrieron, pero quedaron por debajo del umbral de 0,71. Es un argumento para **recalibrar el umbral cada semestre** con los periodos más recientes (plan de seguimiento), no para cambiarlo con la prueba.

¿A quién le funciona peor? Se revisaron los errores en prueba por grupo:

Grupo	Tasa real	Precisión	Exhaustividad
Mañana	0,31	0,94	0,36
Tarde	0,28	0,89	0,43
Noche	0,19	0,86	**0,20**
Sábado	0,01	—	**0** (nunca reserva)
FAFCE	0,28	0,91	0,32
FHCS	0,21	0,82	0,24
FIN	0,28	0,94	0,47

La unidad es la materia, no la persona, así que no hay atributos sensibles que excluir. Aun así, la jornada funciona como indicador de quiénes trabajan. El modelo **reserva menos a quienes estudian de noche y nunca reserva un sábado**, que es justamente el perfil del estudiante que trabaja. Las reservas que sí hace son confiables, pero la herramienta cubre peor a quienes más la necesitan.

6. Decisión, límites y gobernanza

Recomendación para Registro y la Vicerrectoría Académica. Pilotear «Horario Inteligente» como **asistente de sugerencias con reserva confirmada por el estudiante**, no como reserva automática:

1. Se pre-reserva solo cuando el modelo supera el umbral **y** la franja está en el perfil del estudiante, sin choques entre materias. Por su precisión de 0,90, estas reservas son las de

menor riesgo.
2. Para las demás franjas, la herramienta muestra la regla de persistencia como sugerencia, junto con la probabilidad del modelo, y el estudiante decide.
3. Los sábados y las materias con código nuevo se marcan siempre como «revisar a mano».

El cuaderno incluye la función `recomendar()`, y `app.py` la ofrece como servicio web (Streamlit). Ambos usan el mismo modelo e hiperparámetro que defiende este informe, reentrenado sumando 2026-1 una vez evaluado, para predecir **2026-2**. Por ejemplo, para un perfil de martes y jueves en la noche, pre-reserva Cálculo Integral el martes en la noche (p = 0,82) y Cálculo Diferencial el jueves en la noche (p = 0,80), y deja las demás como sugerencia.

Condiciones que invalidan la recomendación.

- Cambio de plan de estudios o de códigos: en 2025-2 solo el 20 % de los códigos tenía historia.
- Cambio de política de jornadas, por ejemplo abrir sábados masivamente.
- Que el costo real de un falso positivo sea 3 veces o más el de un falso negativo.
- Que las reservas empiecen a influir en la programación (bucle de retroalimentación).

Límites del modelo.

- Predice **oferta, no cupo**: una franja abierta puede llenarse.
- No ve docentes, aulas ni demanda, por eso su techo es moderado.
- Con 6 periodos objetivo, la variabilidad entre semestres es alta (DE de 0,17 en PR-AUC).
- El supuesto de que se sabe qué materias abren debe confirmarse con Registro.

A quién puede perjudicar. A estudiantes nocturnos y sabatinos, por el menor recall; a estudiantes de planes nuevos, sin historia; y a docentes, si la oferta se rigidiza.

Correlación y causalidad. El modelo aprovecha regularidades del pasado. No explica por qué una materia va en una franja ni sirve para decidir dónde *debería* ir.

Plan de seguimiento.

1. Al publicarse cada programación, medir la precisión real de las reservas y compararla con la persistencia, desagregada por jornada y facultad.
2. Reentrenar cada semestre con el periodo nuevo y recalibrar el umbral con los dos últimos periodos.
3. Alertar si el porcentaje de materias sin historia supera el 30 % o si la precisión de las reservas cae por debajo de 0,80.
4. Recoger con una encuesta corta la satisfacción y el costo real de un falso positivo, para fijar la razón de costos con datos.

7. Roles y trabajo en equipo

- **Bresleny Benavides (líder, Maestría en Ciencia de Datos):** evaluó la idea y le dio el visto bueno como problema de negocio con datos disponibles. Supervisó cada fase de CRISP-DM y su trazabilidad, revisó la calidad y la gobernanza de los datos (procedencia, exclusión de datos personales y hallazgos del diagnóstico) y validó la métrica de costo con

la que se toma la decisión. Hizo de puente entre la decisión de negocio y el trabajo técnico, y coordinó la redacción y la revisión final de los entregables.
- **Paula Andrea Bustos (crack, Especialización en ML):** propuso la idea a partir de su experiencia como egresada del pregrado de la EAN, donde vivió el problema de armar el horario cada semestre. Diseñó la partición temporal y la validación hacia adelante, hizo la comparación de familias e hiperparámetros, eligió el umbral por costo, hizo la auditoría de fuga y preparó la defensa técnica.
- **Cómo se decidió:** el criterio de elección y la razón de costos se fijaron antes de abrir la prueba. Al ver que la persistencia ganaba en costo en 2026-1, se decidió reportarlo en lugar de re-ajustar.
- **Qué haríamos distinto:** declarar la idea desde el R10 para acumular los retos sobre estos datos; conseguir con Registro los datos de cupos y matrícula; y calibrar el umbral con más periodos.
- **Uso de IA:** está declarado en `declaracion_IA.md`.

Referencias

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data, 6*(4), 1–21. https://doi.org/10.1145/2382577.2382579

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., … Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE, 10*(3), e0118432. https://doi.org/10.1371/journal.pone.0118432

Universidad EAN. (2022–2026). *Programación académica pregrado presencial* [Conjunto de datos, 8 archivos .xlsx, periodos 2022-2 a 2026-1]. Universidad EAN. Consultado el 22 de octubre de 2026, de https://universidadean.edu.co/estudiantes/gestion-de-enlace-academico-administrativo

Universidad EAN. (2026). *Syllabus Machine Learning I* (Formato IAC-201-f1, v.1). Facultad de Ingeniería.

Anexo 1. Correspondencia con CRISP-DM y los retos

Fase CRISP-DM	Reto	Dónde está
Comprensión del negocio	R10	Informe §1; cuaderno §1
Comprensión de los datos	R11	`ficha_datos.md`; cuaderno §2
Preparación	R12	Informe §3; cuaderno §3
Modelado	R13–R14	Informe §4; cuaderno §4 (incluye MLP)
Evaluación	R13, R17	Informe §5; cuaderno §5
Despliegue	R18	Informe §6; cuaderno §6; `app.py`; resumen en inglés

Los retos R15–R17 (no supervisado) no se aplicaron a este problema: la pregunta tiene etiqueta observada y la segmentación no cambiaba la decisión.